




CUDA 优化实验报告

2024010779 刘家豪

测量结果


test_gmem.cu 的 STRIDE

STRIDE	Bandwidth (GB/s)
1	530.113
2	182.494
4	92.001
8	46.287



`test_smem.cu` 的 BITWIDTH 和 STRIDE

BITWIDTH \ STRIDE	1	2	4	8	16	32
2	4306.2	4232.7	2157.9	830.4	427.0	215.6
4	8612.1	4323.9	2025.8	1017.6	509.1	251.5
8	8643.6	4339.5	2173.6	1087.7	544.1	544.1



性能变化来源

性能变化的主要来源是 GPU 的内存合并访问。

- `STRIDE = 1` 时线程访问连续地址，可合并为最少的事务数，带宽最高；`STRIDE >= 2` 时线程访问离散地址，需要发起更多独立事务，带宽随 `STRIDE` 增大而下降。
- 当 `STRIDE` 较小时，缓存命中率较高；`STRIDE` 增大导致空间局部性降低，缓存未命中增加，进一步降低有效带宽。

test_smem.cu

- 固定 `BITWIDTH` 时程序性能变化来源于 **Bank Conflict**。共享内存分为 32 个 bank，当多个线程同时访问同一 bank 的不同地址时发生 bank conflict，访问被串行化，带宽下降。
- `BITWIDTH = 2` 为 16-bit 元素，一个 bank 可存放两个元素，`STRIDE = 1, 2` 时相邻线程访问同一 bank 的不同 16-bit 部分，硬件通过 broadcast 并行处理，无 conflict。
- `BITWIDTH = 4` 为 32-bit 元素，每个元素占 1 个 bank，`STRIDE = 1` 时无 conflict，带宽最高；`STRIDE` 每倍增，conflict 程度倍增，带宽相应减半。
- `BITWIDTH = 8` 为 64-bit 元素，跨 2 个 banks，`STRIDE = 1` 时即产生 2-way conflict；`STRIDE = 16, 32` 时所有线程访问同一 bank 对，达到 32-way conflict，

带宽不再变化。